Journal de bord

Sommaire

Journal de bord 1
I. Projet de Pipeline de la données 1
1.1. Problématique : 1
1.2. Méthodes de travail 1
1.3. Synthèse des différentes phases 2
II. Document de Méthodologie : Ingénierie des données (SQLite) 3
Sources données brutes et aides 3
2.1. **Filtrage et Nettoyage :** Extraction exclusive des données (tri des lignes) 3
2.2. Enrichissement sémantique (Jointures) 5
2.3. Création des scores 6
2.4. Agrégation spatiale (SCORE_IRIS_ORLEANS) 9
2.5. Livrables 10
2.6. Retour critique, comparaison avec la littérature scientifique et pistes d'amélioration ..... **Erreur ! Signet non défini.**

I. Projet de Pipeline de la données

1.1. Problématique :

L'objectif de ce projet est de construire un modèle de scoring spatial pour justifier, par la donnée, le tracé idéal d'une 3ème ligne forte de transport (Tramway ou BHNS). Je m'inspire du ***Transit Potential Score*** (Score de Potentiel de Transport) qui est un indicateur mathématique utilisé en ingénierie des mobilités pour quantifier le besoin ou la capacité d'un territoire à justifier des infrastructures de transports en commun.

1.2. Méthodes de travail

Le travail mené ici est en prompt engineering avec Gemini Pro Max. L'IA joue le rôle d'assistant. Le présent journal de bord permet de suivre l'évolution de mon projet, de m'organiser et d'expliquer mes méthodes.

1.3. Synthèse des différentes phases

Phase 1 : Ingénierie des données (SQLite)

L'objectif de cette phase est de transformer des millions de lignes de données brutes nationales (INSEE) en un indicateur local exploitable.

a. **Filtrage et Nettoyage :** Extraction exclusive des données appartenant aux 22 communes d'Orléans Métropole. (BPE et données populations)

b. **Enrichissement sémantique (Jointures) :** Croisement des codes informatiques de la base de données avec des dictionnaires.

c. **Création de l'Algorithme (Scoring) :** Traduction des règles d'urbanisme en langage mathématique (SQLite) pour attribuer un "Score Émetteur" (besoin de la population) et un "Score Récepteur" (attractivité des équipements).

d. **Agrégation spatiale :** Fusion de tous ces scores à l'échelle du quartier (le code IRIS).

e. **Livrable :** Un fichier CSV Maître conservera l'ensemble des scores bruts intermédiaires (Score Émetteur Brut, Score Récepteur Brut, Score Global Brut). Un CSV contenant les équipements localisés de la métropole.

Phase 2 : Intelligence Spatiale et Aide à la décision (QGIS + Power BI)

L'objectif est de rendre les chiffres intelligibles pour les décideurs publics afin de justifier le tracé. Normalisation [0-100] et Densité du besoin des scores (QGIS / Power BI)

- **Analyse Spatiale (QGIS) :** Importation du fichier CSV maître pour générer une cartographie (carte de chaleur / Heatmap) et du CSV équipements pour localiser les points d'attraction. Passer d'un score global brut à une densité des besoins. Transformer un score brut en note sur 100 pour la lisibilité. Superposition du réseau de transport existant avec des isochrones (zones de marche de 800m) pour faire apparaître visuellement et incontestablement les "zones blanches" (fort potentiel, mais non desservies). Dessin du tracé optimal de la 3ème ligne reliant ces points névralgiques, suivant les voies et connectant les équipements.
- **Tableau de Bord interactif (Power BI) :** Création d'un outil de pilotage pour les élus. Il permet de filtrer dynamiquement le territoire ("Quels sont les quartiers les plus carencés en accès aux pôles d'enseignement ?") via des indicateurs clefs (KPIs) clairs et visuels.

Phase 3 : Industrialisation du processus (Python)

L'objectif est de passer d'une étude ponctuelle à un outil pérenne et automatisé.

- **Automatisation :** Écriture d'un script Python capable d'interroger directement les serveurs de l'État (via API) pour télécharger les nouveaux millésimes de données dès leur publication.
- **Exécution autonome :** Le script lance automatiquement les requêtes SQLite de la Phase 1 pour mettre à jour les scores, permettant aux cartes et aux tableaux de bord de s'actualiser sans aucune intervention manuelle.

Phase 4 : Modélisation 3D et Hyper-réalisme (Blender / BlenderGIS)

L'objectif est de basculer de l'échelle macro (la ville) à l'échelle micro (le trottoir) pour démontrer la faisabilité urbaine.

- Modélisation de l'intégration de la ligne forte dans un tissu urbain dense, en illustrant la mixité fonctionnelle et l'aménagement de l'espace public autour de l'arrêt.

II. Méthodologie Phase 1 : Ingénierie des données (SQLite)

Sources données brutes et aides

Équipements géolocalisés (commerce, services, sport, santé...) en 2025 Base permanente des équipements (BPE) en 2025

https://www.insee.fr/fr/statistiques/8217525#consulter

Table d'appartenance géographique des Iris en 2026

https://www.insee.fr/fr/information/7708995

Population en 2022 Recensement de la population - Base infracommunale (Iris)

https://www.insee.fr/fr/statistiques/8647014

SQLite (Guide pratique)

https://www.sqlite.org/lang_createtable.html

2.1. **Filtrage et Nettoyage :** Extraction exclusive des données (tri des lignes)

A. BPE_ORLEANS

La première étape de la modélisation a consisté à mettre en place un environnement de travail local structuré (/data_brutes, /scripts_sql, /rendus) et à y initialiser une base de données relationnelle via DB Browser for SQLite (tramway_orleans.db).

Afin de garantir l'intégrité et la fiabilité de l'analyse, je me suis appuyé exclusivement sur les données brutes de l'INSEE. J'ai écarté les outils de visualisation interactifs pré-calculés (comme l'outil Melodi) au profit du fichier source massif : la **Base Permanente des Équipements (BPE) géolocalisée à l'IRIS**. Le corpus de données se compose de :

- La BPE brute nationale (format CSV, géolocalisée).
- La table hiérarchisée des types d'équipements (TYPEQU).
- La table de passage des domaines (BPE25_table_passage), indispensable pour traduire les nomenclatures informatiques en catégories intelligibles (ex: "F" vers "Sports, loisirs et culture").

Isolement du périmètre d'étude et optimisation (La méthode CTAS) La table BPE nationale comporte près de 2,9 millions d'enregistrements. Manipuler une telle volumétrie pour une étude locale est contre-productif. Plutôt que d'utiliser une commande DELETE classique (gourmande en ressources et risquée en cas d'erreur), j'ai opté pour la méthode **CTAS** (*Create Table As Select*). J'ai extrait exclusivement les données dont le code INSEE (DEPCOM) appartient aux 22 communes de la métropole d'Orléans pour générer une nouvelle table locale, légère et propre : BPE_ORLEANS.

B. REF_IRIS_ORLEANS (2026)

Pour opérer à une échelle infra-communale (l'IRIS, composé de 9 caractères), il était impératif de construire un dictionnaire géographique de référence. J'ai extrait les 22 communes d'Orléans Métropole à partir du référentiel national. Pour garantir des requêtes SQL performantes et sans erreur d'encodage, j'ai normalisé l'architecture de cette table source en base de données : suppression des espaces, des caractères spéciaux et des accents dans les en-têtes.

Isoler les quartiers (requête CTAS pour créer REF_IRIS_ORLEANS).

C. Populations INSEE (2022)

L'INSEE publie les données de recensement (âge, type de ménage, etc.) à l'échelle des quartiers (IRIS).

Téléchargement du fichier CSV "base-ic-evol-struct-pop-2022" de 22 Mo. Puis nommage en POPULATION_FRANCE.

Dictionnaire des variables disponible ici : https://www.insee.fr/fr/statistiques/8647014#dictionnaire sinon également téléchargé sous le nom meta_base-ic-evol-struct-pop-2022.

Vérifier le nom exact de la colonne contenant le code commune à 5 chiffres ici on a : COM soit d'après l'INSEE le code du département suivi du numéro de commune ou du numéro d'arrondissement municipal pour Paris Lyon et Marseille

Exécution de ma requête de filtrage géographique (Volet C) pour isoler mes 117 quartiers de la métropole et créer ma table locale POP_ORLEANS

2.2. Enrichissement sémantique (Jointures)

Afin d'alimenter efficacement les étapes ultérieures de cartographie (QGIS) et de Business Intelligence (Power BI), j'ai structuré mes tables dans SQLite en anticipant les **deux échelles d'analyse spatiale** nécessaires au projet : l'échelle ponctuelle (l'équipement à l'adresse) et l'échelle surfacique (le quartier IRIS).

Volet A : Table détaillée des Récepteurs (BPE_ORLEANS_TPS)

À partir des 95 variables brutes de la BPE, j'ai réalisé une réduction dimensionnelle et un double enrichissement par jointure (LEFT JOIN) avec la table de passage (BPE25_table_passage) et le référentiel géographique (REF_IRIS_ORLEANS) :

- **Clés et hiérarchie :** Conservation de DCIRIS (code IRIS à 9 caractères pour l'agrégation future), de TYPEQU, ainsi que des libellés explicites (LIBELLE_TYPEQU, LIBELLE_SDOM, LIBELLE_DOM, lib_com, lib_iris). En plus des libellés, quand je vais écrire ma formule de calcul SQL (CASE WHEN) pour le scoring, il est beaucoup plus sûr et rapide d'utiliser les **codes** (SDOM comme 'C1' et DOM comme 'B') donc je les rajoute.
- **Géolocalisation métrique :** Sélection des coordonnées planaires LAMBERT_X et LAMBERT_Y (projection Lambert 93 - EPSG 2154, en mètres) indispensables pour implanter les équipements au mètre près sous QGIS et calculer les isochrones piétons (400m / 800m).
- **Pondération :** Conservation des indicateurs de dimensionnement (CAPACITE, NBSALLES) en écartant les métadonnées administratives (INDIC_CAPA, CAPACITE_D_ACCUEIL).

- **Rôle dans le pipeline :** Cette table a une double vocation. Elle servira d'abord de base de calcul pour agréger le *Score Récepteur* par quartier (Étape 2.3/2.4), mais sera également exportée telle quelle comme **couche de points détaillée** pour localiser précisément les générateurs de trafic (hôpitaux, lycées) lors du tracé final de la 3ème ligne.

Volet B : Table des Émetteurs démographiques (POP_ORLEANS_TPS)

L'analyse du dictionnaire INSEE du recensement 2022 m'a conduit à isoler 7 variables clés sur les 117 IRIS de la métropole :

- **Captifs par l'âge :** jeunes/étudiants de 18 à 24 ans (P22_POP1824) et (P22_POP1117 pour les 11-17 ans) soient les collégiens et lycéens enfin les seniors de 65 ans et plus via la variable agrégée P22_POP65P.
- **Approche par variables « Proxys » pour la vulnérabilité économique :** Afin d'éviter l'écueil du secret statistique inhérent aux bases fiscales et allocataires (Filosofi, CAF) sur les petites communes périurbaines, j'ai retenu deux proxys exhaustifs issus du recensement : le volume d'ouvriers (C22_POP15P_STAT_GSEC16_26, sujets aux horaires décalés) et les personnes sans activité professionnelle (C22_POP15P_STAT_GSEC40, fortement captives des transports publics).
- **Calcul de la densité de besoins :** Pour respecter la séparation des rôles entre les outils, SQLite traite le volume brut de population (P22_POP) qui servira pour calculer le score pondéré émetteur. Sur QGIS, la densité des besoins sera calculée dynamiquement en divisant le score par la superficie géométrique officielle des polygones ($area).
- **Optimisation relationnelle :** Contrairement aux équipements qui possèdent des coordonnées ponctuelles, la population est d'emblée rattachée au polygone IRIS (IRIS). Il est donc inutile d'y joindre les libellés de communes à ce stade : la jointure s'effectuera lors de la fusion finale (Étape 2.4) autour de REF_IRIS_ORLEANS.

2.3. Création des scores

L'objectif de cette étape est de traduire des règles d'urbanisme et de mobilité en langage mathématique (SQL) afin d'attribuer deux indicateurs complémentaires : un **Score Émetteur** et un **Score Récepteur**.

Choix d'architecture logicielle (Idempotence des scripts) : Lors de mes premiers tests avec la commande ALTER TABLE ... ADD COLUMN, je me suis heurté à une limite technique de SQLite : l'impossibilité de relancer le script pour ajuster mes pondérations sans déclencher une erreur bloquante (duplicate column name: score_pop). Pour rendre

mon code réexécutable à l'infini (idempotent) et facilement maintenable, j'ai opté pour une recréation propre des tables (DROP TABLE IF EXISTS suivi de CREATE TABLE ... AS SELECT) intégrant directement les formules de calcul.

Volet A : Modélisation du « Score Émetteur » (score_pop sur POP_ORLEANS_TPS)

Le potentiel émetteur repose sur le recensement INSEE 2022 à l'IRIS. Chaque habitant de la métropole constitue une demande potentielle de base (socle de référence fixé à 1 point). Afin de cibler prioritairement les **publics captifs** (dépendants des transports collectifs pour des raisons d'âge, de non-motorisation ou de vulnérabilité économique), j'ai appliqué un système de bonus cumulatifs.

La population totale (P22_POP) incluant déjà l'ensemble des résidents (1 point de base), la formule SQL additionne uniquement le **surpoids (bonus)** attribué à chaque catégorie.

Volet B : Modélisation du « Score Récepteur » (score_bpe sur BPE_ORLEANS_TPS)

La Base Permanente des Équipements (BPE) comportant près de 200 codes d'équipements distincts (TYPEQU), une pondération manuelle code par code au sein de la requête aurait alourdi le script. J'ai donc conçu une **matrice stratifiée à 3 niveaux** exploitant l'évaluation séquentielle de l'instruction SQL CASE WHEN (qui teste les conditions de la plus précise à la plus large et s'arrête dès qu'une correspondance est trouvée) :

- **Niveau 1 — Les « Locomotives » urbaines (Ciblage fin par TYPEQU / SDOM) :** Poids très élevé (50 à 150 points) pour les infrastructures structurantes qui génèrent des milliers de déplacements quotidiens à heures fixes ou assurent le rabattement multimodal (gares ferroviaires, pôles hospitaliers lourds, lycées, universités, résidences CROUS, hypermarchés).
- **Niveau 2 — Les « Centralités de quartier » (Ciblage intermédiaire par SDOM) :** Poids moyen (20 à 30 points) pour les équipements qui structurent la vie locale et lissent la fréquentation du tramway/BHNS en heures creuses et le week-end (écoles primaires, collèges, centres de formation d'apprentis, maisons de santé, services publics administratifs, équipements sportifs et culturels).
- **Niveau 3 — Le « Tissu d'hyper-proximité » (Ciblage large par DOM) :** Poids unitaire de base (2 à 10 points) pour l'ensemble des petits commerces, cabinets médicaux libéraux, services touristiques et services courants. Ce niveau récompense par effet cumulatif l'hyper-densité fonctionnelle et la mixité urbaine d'un quartier.

Audit de la base et arbitrages métiers (Élimination des « faux positifs »)

L'analyse critique de la table de passage (BPE25_table_passage) m'a conduit à effectuer cinq corrections majeures pour éviter les biais algorithmiques :

1. **Neutralisation des sièges d'artisans du BTP (SDOM = 'A4' -> 0 point) :** La BPE recense les maçons, plombiers, peintres et électriciens à leur domicile ou dépôt. Or, ces professionnels se déplacent chez leurs clients en véhicule utilitaire et ne génèrent aucun flux de voyageurs en transport collectif. Leur attribuer des points aurait artificiellement gonflé le score des zones pavillonnaires et artisanales.

2. **Exclusion des équipements purement automobiles et logistiques (0 point) :** Les déchèteries (A133), stations-service (B316), bornes de recharge électrique (B326), garages/contrôles techniques (A301 à A303) et artisans taxis domiciliés (E101) ont été forcés à 0 point en tête de script. Seules les auto-écoles (A304) ont été maintenues à 5 points car elles sont fréquentées par un public jeune non motorisé.

3. **Intégration complète de l'écosystème étudiant et apprenti (C4, C6, C7) :** Au-delà des UFR universitaires (C5), j'ai intégré au niveau maximal (100 points) l'enseignement supérieur non-universitaire (SDOM = 'C4' : BTS, CPGE, écoles d'infirmiers/commerce) ainsi que les résidences et restaurants universitaires du CROUS (SDOM = 'C7'). Les centres de formation continue et d'apprentissage (SDOM = 'C6' : GRETA, CFA) ont été valorisés à hauteur de 30 points.

4. **Hiérarchisation fine du commerce (B1) et de la santé (D1, G1) :** Distinction entre l'attractivité régionale d'un hypermarché (B104 à 100 points), celle d'un supermarché (B105 à 50 points) et d'une grande surface de bricolage (B103 à 20 points). En santé, inclusion des maternités (D107) dans les pôles hospitaliers lourds (100 points) et valorisation des structures ambulatoires/maisons de santé pluridisciplinaires (D108 à D115) à 30 points. Enfin, le secteur du tourisme (DOM = 'G', notamment les hôtels G102) reçoit 10 points en raison de la forte captivité des voyageurs arrivant par le train et des emplois hôteliers en horaires décalés.

5. **Écartement de la variable CAPACITE du calcul mathématique :** Selon le dictionnaire officiel de l'INSEE, la variable CAPACITE souffre d'une forte hétérogénéité d'unités (nombre d'élèves, de chambres d'hôtel, de fauteuils de cinéma) et comporte des valeurs manquantes (NA) sur des pôles majeurs comme les hôpitaux (D101) ou les universités (C501). Pour garantir l'équité mathématique du modèle, le calcul SQL repose à 100 % sur le barème de points fixes détaillé dans la matrice Grille_Ponderation_BPE.pdf et synthétisé sur la page d'accueil du dépôt (README.md), tandis que CAPACITE et NBSALLES sont conservées comme métadonnées descriptives pour les infobulles sous QGIS et Power BI.

2.4. Agrégation spatiale (SCORE_IRIS_ORLEANS)

L'étape finale de modélisation sous SQLite consiste à fusionner le potentiel démographique (POP_ORLEANS_TPS, structuré à l'échelle des 117 IRIS) avec le potentiel d'attractivité des équipements (BPE_ORLEANS_TPS, structuré à l'échelle ponctuelle de chaque établissement).

1. **Architecture de la requête et choix de la table pivot (REF_IRIS_ORLEANS) :**

Bien que les libellés de communes et de quartiers aient déjà été joints à la table BPE_ORLEANS_TPS lors de l'étape 2.2, il aurait été risqué de partir de cette table pour effectuer la fusion finale. En effet, un quartier IRIS dépourvu d'équipements (zone forestière ou secteur purement pavillonnaire) est absent de la BPE : utiliser un INNER JOIN ou partir de BPE_ORLEANS_TPS aurait supprimé ces quartiers de la carte finale. De plus, la table POP_ORLEANS_TPS ne contenait que le code numérique IRIS sans les noms en clair. J'ai donc utilisé le référentiel officiel REF_IRIS_ORLEANS (117 lignes) comme colonne vertébrale (FROM), sur laquelle viennent se greffer deux jointures externes (LEFT JOIN) vers la population et les équipements. Cette architecture garantit la conservation stricte des 117 polygones de la métropole.

2. Changement d'échelle (GROUP BY) et sécurisation mathématique (ROUND vs IFNULL) :

- **Agrégation par quartier :** La clause GROUP BY iris.Code_Iris permet de passer de l'échelle de l'équipement (plusieurs milliers de lignes) à l'échelle du quartier (117 lignes) en additionnant les points d'attractivité via SUM(bpe.score_bpe) et en comptabilisant le nombre total d'établissements via COUNT(bpe.TYPEQU).
- **Arrondi des pondérations INSEE (ROUND(var, 0)) :** Le recensement INSEE utilisant des pondérations statistiques décimales, la fonction ROUND(..., 0) (arrondi à 0 chiffre après la virgule) permet de restituer des volumes d'habitants entiers.
- **Gestion des valeurs nulles (IFNULL(var, 0)) :** En langage SQL, l'addition d'un score démographique avec une valeur NULL (cas d'un IRIS sans aucun équipement) renvoie NULL. L'encapsulation dans IFNULL(..., 0) force SQLite à convertir l'absence d'équipement en valeur numérique 0, sécurisant ainsi l'addition du SCORE_TPS_GLOBAL_BRUT.

3. Sélection finale des variables et nettoyage des redondances :

- **Élimination de CODE_COM :** Le code commune à 5 chiffres correspondant déjà aux 5 premiers caractères du CODE_IRIS et le nom de la commune (NOM_COMMUNE) étant affiché en clair, cette variable redondante a été écartée.

- **Conservation de CODE_IRIS et TYPE_IRIS :** CODE_IRIS (9 chiffres) est conservé comme clé primaire indispensable pour réaliser la jointure géométrique avec le fond de carte IGN sous QGIS. L'indicateur TYPE_IRIS (H Habitat, A Activité, D Divers, Z Non-irisé) est maintenu pour qualifier les profils atypiques lors de l'analyse spatiale (ex: expliquer pourquoi une zone industrielle A présente un fort score d'équipements malgré une population nulle).
- **Conservation des sous-totaux démographiques :** Le maintien des volumes par tranche d'âge et catégorie socio-professionnelle (POP_11_17_ANS, POP_18_24_ANS, POP_65_ANS_PLUS, POP_OUVRIERS, POP_SANS_ACTIVITE) permettra d'alimenter les graphiques explicatifs du futur tableau de bord Power BI.

2.5. Livrables

L'aboutissement du pipeline SQLite se traduit par l'exportation de **deux fichiers CSV complémentaires**, répondant aux deux échelles d'analyse de la Phase 2 (QGIS et Power BI) :

1. **Le CSV Maître surfacique : SCORE_IRIS_ORLEANS.csv (117 lignes — Échelle Macro / Quartier)**
    - **Contenu :** Issue de la grande fusion (Étape 2.4), cette table regroupe pour chacun des 117 IRIS son identification, ses effectifs démographiques détaillés, son nombre d'équipements, ainsi que ses trois indicateurs bruts (SCORE_EMETTEUR_BRUT, SCORE_RECEPTEUR_BRUT et SCORE_TPS_GLOBAL_BRUT).
    - **Usage en Phase 2 :** Ce fichier sera joint au *Shapefile* des polygones IRIS sous QGIS pour calculer la densité réelle des besoins au km² (Score / $area), normaliser les scores sur une échelle de 0 à 100 et générer la carte de chaleur (*Heatmap*) mettant en évidence les zones blanches du réseau TAO.
2. **Le CSV de détail ponctuel : BPE_ORLEANS_TPS.csv (Échelle Micro / Adresse)**
    - **Contenu :** Chaque ligne correspond à un équipement géolocalisé de la métropole avec son nom (NOMRS), sa hiérarchie thématique (LIBELLE_DOM, LIBELLE_SDOM, LIBELLE_TYPEQU), ses coordonnées métriques (LAMBERT_X, LAMBERT_Y en projection Lambert 93 - EPSG 2154) et son poids d'attractivité individuel (score_bpe).
    - **Usage en Phase 2 :** Une fois les quartiers prioritaires identifiés grâce au CSV Maître, cette couche de points permettra d'afficher sous QGIS l'emplacement exact des générateurs de flux (hôpitaux, lycées, pôles

d'emplois) à l'échelle de la rue pour tracer finement la 3ème ligne de tramway/BHNS, et servira de filtre catégoriel dynamique sous Power BI.

Paramétrage technique de l'export : Les deux tables ont été exportées avec en-têtes en première ligne, séparateur virgule (,), encadrement des chaînes de caractères par des guillemets doubles (") afin de neutraliser les virgules internes aux raisons sociales, et encodage standard garantissant une interopérabilité immédiate avec QGIS, Power BI et la visionneuse native de GitHub.